


AUC: 0.9157 → 0.1104

100,000 件の同一レビュー集合・ラベル改変なし・重複なし

1 | 問い：順序だけで学習結果は壊せるか？

- 2条件で固定するもの：
- ▶ 同じ **100,000 件** の Yelp レビューと source label
 - ▶ 同じ語彙、モデル初期値、テスト集合、optimizer
 - ▶ 違いは訓練イベントの **permutation だけ**
- $D = A \cup B,$ $\pi_{\text{random}} = \text{Shuffle}(D),$ $\pi_{\text{attack}} = \text{Shuffle}(A) \parallel \text{Shuffle}(B).$


2 | データ構成：selector と target を分離




3 | 監査可能な「順序だけ」の比較

- ✔ common-event SHA-256 で同一 multiset を確認
- ✔ source label を保持：label flip なし
- ✔ selector 集合と target 集合は disjoint
- ✔ 重複レビュー 0、初期 parameter digest 一致

4 | 記録済み LSTM 結果：ランキングが反転




5 | full-scale 10セル：非線形モデルで大幅低下




最大 Δ AUC：−0.8869 (Transformer Encoder–Decoder + Adam)


6 | 何が効いている？



7 | Isabelle/HOL：有限証明から漸近反転へ



8 | 証明スタックと optimizer 範囲



9 | 再現方法と適用範囲

```
uv run bad-curriculum
--device cuda
--output-dir results/order-only
```

重要な境界：

- ▶ すべての順序が有害なのではない。固定特徴の線形モデルは full-scale で低下しない。
- ▶ 形式証明は明示的な order-only model に対するもの。任意の LSTM への無条件定理ではない。
- ▶ Tail 選択は別 selector で行うが、target の訓練 label は常に source label。

コード・結果・形式証明

github.com/tani/bad-curriculum