

Bad Curriculum

同じデータ、同じラベル。違う順序だけで予測を反転させる

LSTM AUC : 0.9157 → 0.1104

100,000 件・ラベル改変なし・重複なし
PyTorch 実験 × Isabelle/HOL 形式証明


1 | 問い：順序だけで学習結果は壊せるか？

2条件で固定するもの：

- ▶ 同じ**100,000**件のYelpレビューとsource label
- ▶ 同じ語彙、初期値、モデル、optimizer、テスト集合
- ▶ 違いは訓練イベントの**permutation**だけ

$D = A \cup B$ を固定し、 π_{random} と π_{attack} だけを比較する。

2 | データ構成：selectorとtargetを分離



3 | 記録済みLSTM結果：ランキングが反転

Random order
AUC 0.9157

Anchor → Tail
AUC 0.1104

Accuracy
83.01%

Accuracy
19.93%

AUC < 0.5 : 精度低下ではなく、positive class を系統的に逆順位付け。

4 | 監査可能な「順序だけ」の比較

- ✓ common-event SHA-256 で同一 multiset を確認
- ✓ source label を保持：label flip なし
- ✓ selector 集合と target 集合は disjoint
- ✓ 重複レビュー0、初期parameter digest一致

5 | 何が効いている？


Anchor
表現を形成

Tail
強い修正勾配


$\Phi_B^m(\Phi_A^n(\theta_0)) \neq \Phi_A^n(\Phi_B^m(\theta_0))$

非線形な更新写像は一般に可換でない。Tailはlabel poisonではない。
source labelを使った大きな修正 updateが、最後にモデルを上書きする。


6 | 実験結果：full-scale 10セル



7 | 形式証明（条件付き）：有限証明から漸近反転へ



8 | 証明スタックとoptimizer範囲



9 | 再現方法と適用範囲

```
uv run bad-curriculum
--device cuda
--output-dir results/order-only
```

重要な境界：

- ▶ 固定特徴の線形モデルはfull-scaleで低下しない。
- ▶ 形式証明は明示的なorder-only modelに対する条件付き結果。任意のLSTMへの無条件定理ではない。
- ▶ Tail選択は別selectorで行うが、targetの訓練labelは常にsource label。

コード・結果・形式証明
github.com/tani/bad-curriculum